

王冠 Wang Guan

大模型后训练 / 基础模型算法 / 数据与训练 Recipe / 模型评测 / 机制分析

电话: 17600734418 | 邮箱: wangguan@iie.ac.cn | 26 岁 | 北京 | 2026.07 起可实习 6 个月以上 | 预计毕业 2027.07

个人简介

中国科学院大学信息工程研究所直博生，研究方向为大模型后训练、安全对齐、训练时推理、数据与训练 recipe、模型可解释性分析与鲁棒对齐。独立一作完成 8 篇 LLM Safety / Alignment 论文，其中 2 篇 ACL 2026 Main，2 篇 EMNLP 2026 预计收录（Meta 5 / Meta 4），另有多篇审稿中/预印版工作。

全流程参与训练数据构建、偏好数据设计、模型轨迹采集、SFT / DPO / RLHF / RLAIF / GRPO 后训练、checkpoint ablation、能力保持 / 回退评估、机制归因与批量推理评测 pipeline；安全是主要落地场景，能力可迁移至通用后训练、持续预训练 / 中训练数据 recipe、Agent / 代码能力训练和模型评测岗位。

教育背景

中国科学院大学，中国科学院信息工程研究所 直博生 2022.09 - 2027.07

导师：虎嵩林 研究员、韩冀中 正高级高级工程师；研究方向：大语言模型的鲁棒安全对齐及其脆弱性机制解释、模型后训练、越狱攻防与安全评测。

北京工业大学 本科 2018.09 - 2022.06

核心能力

- 后训练与 Alignment**：SFT 固化指令与安全规范，DPO 校准安全 / 有用偏好和拒答边界，RLHF / RLAIF 安全对齐训练与优化 judge 驱动策略，GRPO 支持多候选推理策略，安全思维链与鲁棒对齐，专项能力后训练，后训练优化，强化学习算法。
- 数据与训练 Recipe**：红队模型与数据集构造、偏好样本、安全思维链与行为数据、模型轨迹、Agent tool-call 轨迹、Oday 漏洞挖掘轨迹、模型漏洞挖掘能力评测轨迹与分步自动化标注、模型代码 / 漏洞挖掘 harness 轨迹、合成数据、训练 recipe、清洗配比、质量评估与数据污染检查。
- Checkpoint 评测与 Ablation**：自动化评测、LLM-as-Judge 校准、模型能力保持、能力回退、对齐税缓解、ASR / 过拒率 / 通用能力 trade-off 分析与平衡。
- 基础模型机制分析**：FFN 参数内化、latent CoT / latent reasoning、表示分析、probe、activation / causal intervention、基于注意力的越狱攻击分析与指引、神经元与神经元回路机制。
- 训练与推理工程**：Python、Vibecoding、PyTorch、Transformers、HuggingFace、Linux、Docker、CUDA、多卡训练、批量推理、vLLM、SGLang、ollama、Ray、FSDP、OpenRLHF、verl。
- 鲁棒性与泛化**：弱到强迁移、训练时推理、能力泛化、长尾边界样本、拒答边界、能力保持、安全性与有用性 trade-off。
- Agent / 代码能力应用**：工具调用、RAG / Memory、漏洞挖掘、多 agent 社群协同攻击/防护/漏洞挖掘、PoC 生成、利用链构建、sandbox 验证、模型轨迹数据构建与训练数据来源沉淀。

重点项目

大模型自动化安全后训练与鲁棒对齐平台

2023 - 2026

- 全流程参与后训练和对齐算法优化、红队 badcase 挖掘、偏好数据 schema 设计、SFT / DPO / RLHF / RLAIF / GRPO 训练、checkpoint 回归评测和失败样本回流；支持多种对齐训练，SFT 用于固化任务格式、拒答规范和边界场景识别，DPO 用于安全 / 有用偏好对比与过拒修复，RLHF / RLAIF 进行对齐和策略优化，GRPO 用于安全思维链能力构建和多候选推理策略下的鲁棒对齐。基于 Qwen / Llama / Mistral / Vicuna 等模型持续评估 ASR、过拒率、通用能力保持、alignment tax 和能力回退。形成自动评测数据集构建、对抗条件对齐训练、模型能力评测与行为分析的闭环。

国家级大模型安全评测与生产级评测 Pipeline

2024 - 2026

- 核心参与多轮国家级 / 各级大模型安全能力评测，承担风险维度分类、红队样本构建、判定标准、LLM-as-Judge 校准、人工复核与结果归因；围绕安全靶场、Agent 靶场、漏洞评测和后训练回归评测搭建批量推理 pipeline，支持 checkpoint 对比、能力保持分析和多份风险评估报告交付，为模型迭代和数据 recipe 调整提供依据。

大模型内容安全攻防靶场与红队评测平台

2023 - 2026

- 核心参与安全对齐模型训练、鲁棒的对齐算法优化、越狱攻击样本库、红队模型训练、对抗下安全对齐训练、自动判定、人工复核与评测报告生成；从涉政言论、违法违规、隐私泄露、高风险专业建议、色情暴力等风险中构造万级 badcase、边界偏好样本和模型拒答 / 失效轨迹，覆盖二十余种攻击方式与四十余种模型，作为后训练数据来源、checkpoint 回归集和安全能力 ablation 基准。

漏洞挖掘能力评测

2026

- 从 Oday 漏洞挖掘、现有 CVE 转化、harness 优化和 sandbox 真实环境验证等途径构建代码能力与安全能力 benchmark，针对主流模型进行漏洞定位、PoC 生成、利用链构建、多模型协同挖掘、轨迹收集与训练数据构建，评测与增强模型漏洞挖掘能力；积累千余条任务、万余条轨迹、五十万标注步骤，沉淀代码推理、工具调用、失败修复和偏好训练数据来源。

Agent 安全靶场

2024 - 2026

- 构建 Agent 安全任务与代码安全评测框架，覆盖 RAG 注入、工具越权、长期记忆污染、敏感信息泄露、沙箱逃逸、多 Agent 协作绕过、多模型协同防御、Agent 蠕虫传播与防治、skill 构建/优化/融合；将 tool-call 序列、RAG 命中文档、memory diff、sandbox 执行结果和多步规划轨迹转化为模型轨迹数据，支撑工具调用能力评测、Agent / 代码训练数据构建和回归评测。

国家重研课题-交易社群异常识别与任务画像

2022 - 2025

- 构建交易社群网络异常账户、行为风险识别与账户画像能力，构建社群交易数据集、异常风险识别模型训练、账户画像模型训练，交付交易社群风险报告与账户风险画像报告。

代表论文

More Thinking, Less Talking: Internalizing Deliberative Safety into LLM Parameters

ACL 2026 Main, 独立一作

- 提出 HIAR，将显式 Safety-oriented CoT 基于闭式解分层内化到低秩的模型 FFN 参数中，使模型在单次前向传播中完成隐式安全推理；覆盖 5 个主流 LLM 和多类越狱攻击，ASR 相比强基线降低 43.2%。

Resolving the Security-Auditability Dilemma with Auditable Latent Chain-of-Thought

ACL 2026 Main, 独立一作

- 提出 ALCA，将安全 CoT 从文本空间转移到连续 latent space 中，并通过 Self-Decoding 重构为可审计文本，在高效的推理计算时兼顾了思维链的可审计和隐蔽性；adaptive jailbreak 成功率相比强基线降低 54% 以上，平均 ASR 约 9.4%，语义相似度约 0.9%。

Pretending to Think: Unmasking and Eliminating Post-Hoc Rationalization in LLM Safety Chain-of-Thought

EMNLP 2026 Under Review, Meta 5, 独立一作

- 揭示安全 CoT 中的伪推理现象，发现模型拒答决策常在安全推理生成前已收敛，推理过程反受基于浅层特征的决策约束且难以对安全决策产生因果影响；提出 Safety-as-Reasoning，通过构建反事实数据集和时序/一致性训练约束与损失优化，增强安全推理因果性、降低过拒并提升越狱鲁棒性。

From Shallow Alignment to Source Correction: Robust Safety Alignment for LLMs

EMNLP 2026 Under Review, Meta 4, 独立一作

- 诊断 Depth-wise Alignment Discrepancy，发现有害向量主要在低层产生而常规安全对齐梯度集中在高层；提出 SAGA，通过建模数据集的熵值与训练梯度分布的关系，通过构建高熵数据集，将安全梯度引导到脆弱低层以消除这种分布差异，ASR 相比 SOTA 降低 21%-63%，额外开销小于 3%。

From Chain to Mesh: Evolving Robust Safety Alignment via Neuron-Circuit Topology

EMNLP 2026 Under Review, o1.5, 独立一作

- 从神经元回路拓扑解释安全对齐脆弱性以及局部失效和整体能力崩溃的关联；超越静态的神经元功能分析，建模神经元回路并发现安全回路的拓扑缺陷；提出 DSM 将安全神经元回路从脆弱单链结构转化为鲁棒网状结构；在多类越狱/微调/编辑扰动下具有更强的鲁棒性，并保持通用任务能力，动态 DSM 在迭代攻击中可将 ASR 维持在 3% 以下。

Think While You Learn: Deliberative Safety Training for Generalizable LLM Alignment

ICLR 2027 预投稿, 独立一作

- 提出模型自我能力认知不足源自于模型缺乏学习外界对自身输出结果的评价与反馈，构建自动化自我认知训练流程；构建训练阶段的模型自我能力认知与审慎式学习框架，利用模型自身推理能力边思考边学习，增强数据风险识别与过滤、规则抽象、行为泛化和自我反思，并扩展到安全、代码、语言、数学等能力的数据构建与模型训练。同时构建基于自我认知的自身评测数据集构建、训练时推理介入、训练数据优化和模型能力与认知同步训练全流程。

Safety Collapse: Revealing Representation Competition in LLM Safety Signals and Orthogonal Decomposition for Safer Generation

ICLR 2027 预投稿, 独立一作

- 揭示安全推理与非安全任务推理的在隐藏特征空间中的竞争与崩塌，在隐藏空间超越单一任务方向建模更精准的能力方向簇；提出 PRISM 正交表征干预方法，通过识别模型多任务竞争并拆分为并行推理实现多任务能力的保持；在 6 个主流 LLM 上同时降低攻击成功率和过拒绝率，ASR 平均下降约 28 个百分点、过拒绝率下降约 12 个百分点。同时在安全、数学、代码、语言、推理等多领域验证且适用。

AgentVax: Turning Multi-Agent Communities from Safety Liabilities into Collective Defense

USENIX Security 预投稿, 独立一作

- 基于各类智能体在社交平台面对注入攻击时自发产生互相提醒的现象，提出 AgentVax 多智能体安全防御框架，将 Agent 安全从单模型拒答扩展到社群级风险协同治理，实现智能体社群免疫；构建 Input / RAG / Memory / Agent-Message / Tool-Chain Worm 评测，建模蠕虫传播与攻击抗体补丁传播的传播学对抗场景，并提出攻击免疫补丁 skill 的构建、优化、融合、传播与可信验证完整流程框架。

竞赛荣誉与学术服务

- 2024 生成式人工智能安全大赛：越狱攻击赛道前三名、安全对齐赛道前三名。
- 本科及博士期间连续六年获得优秀学生/一等奖学金与三好学生。
- 大模型对齐训练专利 4 项，交易社群异常风险识别专利一项均处于公示阶段。
- 参与 ACL、AAAI 等 CCF A 类会议审稿。

个人评价

- 学习与迁移**：习惯用论文精读、源码复现、实验 ablation 和失败案例复盘建立新方向认知，行动力强，能迅速把后训练、Agent、代码能力等新问题拆成数据、训练、评测和机制假设。
- 工作方式**：偏研究工程结合，重视可复现、指标可信和长期积累；性格稳定、执行力强，能在模糊目标下主动推进，并与算法、工程、评测同学协作落地。