

王冠 Wang Guan

大模型安全算法 / 安全后训练 / 红队评测 / Agent 与代码安全 / Safety Alignment

电话: 17600734418 | 邮箱: wangguan@iie.ac.cn | 26 岁 | 北京 | 2026.07 起可实习 6 个月以上 | 预计毕业 2027.07

个人简介

中国科学院大学信息工程研究所直博生，研究方向为大语言模型安全对齐、红队评测、内容安全、Agent 安全、模型漏洞挖掘能力和模型安全机制分析。独立一作完成 8 篇 LLM Safety / Security / Alignment 论文，其中 2 篇 ACL 2026 Main，2 篇 EMNLP 2026 Under Review（Meta 5 / Meta 4），另有多篇审稿中/预印版工作。

全流程参与大模型安全攻防靶场、Agent 安全靶场、国家级大模型安全能力评测、漏洞挖掘能力评测与提升、大模型自动化安全后训练与鲁棒对齐平台，核心承担风险体系构建、攻击样本与红队模型构造、LLM-as-Judge 校准、人工复核、SFT / DPO / RLHF / RLAI / GRPO 安全对齐、安全与通用任务能力保持、checkpoint 回归和评测报告交付等环节。

教育背景

中国科学院大学，中国科学院信息工程研究所 直博生 2022.09 - 2027.07

导师：虎嵩林 研究员、韩冀中 正高级高级工程师；研究方向：大语言模型安全对齐及其脆弱性、模型后训练、越狱攻防与安全评测。

北京工业大学 本科 2018.09 - 2022.06

核心能力

- 红队评测与内容安全**：风险体系构建、越狱 / 多轮诱导 / 编码绕过 / CoT 诱导 / 自适应攻击，红队模型自动化训练，攻击样本自动生成，多模型协同攻击，万级安全数据、四十余种模型评测、风险画像与报告交付。
- 自动评测与 Judge 校准**：LLM-as-Judge rubric、多模型交叉判定、人工抽检复核、误判归因、judge 一致性校准、checkpoint 安全回归。
- Agent 与代码安全**：RAG / Prompt 注入、工具越权、长期记忆污染、敏感信息泄露、sandbox 逃逸、智能体渗透/破坏/蠕虫/间接注入，PoC 生成、利用链构建与真实沙箱验证。
- 安全后训练**：对抗条件下的鲁棒安全对齐训练，安全对齐优化，安全对齐数据集构建，智能体安全对齐，基于 skill 的安全补丁生成与优化，多智能体协同防御。
- 训练数据与轨迹构建**：安全数据 recipe、攻击 / 防御轨迹、模型拒答轨迹、Agent tool-call 轨迹、漏洞挖掘 harness 轨迹、合成数据与人工复核数据沉淀。
- 机制分析与可解释性**：FFN 参数内化、latent CoT、表示分析、probe、activation / causal intervention、基于注意力的越狱攻击分析与指引、神经元与神经元回路机制。
- 工程工具**：Python、Vibecoding、PyTorch、Transformers、HuggingFace、Linux、Docker、CUDA、多卡训练、vLLM、SGLang、Ray、OpenRLHF、verl。

重点项目

大模型内容安全攻防靶场与红队评测平台

2023 - 2026

- 全流程参与平台建设，核心承担风险体系构建、红队样本库与模型构建、攻击 / 防御轨迹数据、红队模型训练、自动判定与人工复核流程；构建与优化高攻击手段：越狱、多轮诱导、编码绕过、协同攻击、CoT 诱导和自适应攻击，构造万级评测数据，覆盖涉政言论、违法违规、隐私泄露、高风险专业建议、色情暴力等风险；建立 LLM-as-Judge rubric、多模型交叉判定、人工抽检和误判归因机制，支撑四十余种模型评测、风险画像和多轮报告交付。防御侧参与实现偏好数据 schema 设计、强化学习对齐训练、对齐优化、checkpoint 回归评测和失败样本回流。

Agent 安全靶场

2024 - 2026

- 核心参与 Agent 安全任务与代码安全评测框架建设，覆盖 RAG 注入、工具越权、长期记忆污染、敏感信息泄露、沙箱逃逸、多 Agent 协作绕过、多模型协同防御和 Agent 蠕虫传播；将 tool-call 日志、memory diff、RAG 命中文档、sandbox 执行结果和防御轨迹沉淀为模型轨迹数据与回归样本，形成工具权限边界、任务 harness、可信验证和防御策略评估流程。

漏洞挖掘能力评测

2026

- 全流程参与从 0day 漏洞挖掘、现有 CVE 转化、harness 优化和 sandbox 真实环境验证等途径构建代码能力与安全能力 benchmark，针对主流模型进行漏洞定位、PoC 生成、利用链构建、多模型协同挖掘、轨迹收集与训练数据构建，评测与增强模型漏洞挖掘能力；积累千余条任务、万余条轨迹、五十万标注步骤，沉淀代码推理、工具调用、失败修复和偏好训练数据来源。

国家级大模型安全评测与生产级评测 Pipeline

2023 - 2026

- 核心参与多轮国家级 / 各级大模型安全能力评测，承担风险维度设计、红队样本构造、判定标准制定、自动评测、人工复核、结果归因和报告交付；围绕安全靶场、Agent 靶场、漏洞评测和后训练回归评测搭建批量推理 pipeline，支持模型风险画像、checkpoint 对比、策略缺陷定位和多份风险评估报告交付。

大模型自动化安全后训练与鲁棒对齐平台

2023 - 2026

- 全流程参与红队 badcase 挖掘、安全数据 recipe、训练 recipe、对齐训练、checkpoint 回归和失败样本回流：支持多种安全对齐训练范式，SFT 用于固化安全规范、拒答格式和边界场景识别；DPO 用于安全 / 有用偏好对比、拒答边界和过拒修复；RLHF / RLAIF 用于基于人工或 AI judge 的安全策略优化；GRPO 用于多样候选与推理策略下的鲁棒对齐。基于 Qwen / Llama / Mistral / Vicuna 等模型分析 ASR、过拒率、通用能力保持和 alignment tax，为安全策略迭代提供可复用闭环。

国家重研课题-交易社群异常识别与任务画像

2022 - 2025

- 构建交易社群网络异常账户、行为风险识别与账户画像能力，构建社群交易数据集、异常风险识别模型训练、账户画像模型训练，交付交易社群风险报告与账户风险画像报告。

代表论文

More Thinking, Less Talking: Internalizing Deliberative Safety into LLM Parameters

ACL 2026 Main, 独立一作

- 提出 HIAR，将显式 Safety-oriented CoT 基于闭式解分层内化到低秩的模型 FFN 参数中，使模型在单次前向传播中完成隐式安全推理；覆盖 5 个主流 LLM 和多类越狱攻击，ASR 相比强基线降低 43.2%。

Resolving the Security-Auditability Dilemma with Auditable Latent Chain-of-Thought

ACL 2026 Main, 独立一作

- 提出 ALCA，将安全 CoT 从文本空间转移到连续 latent space 中，并通过 Self-Decoding 重构为可审计文本，在高效的推理计算时兼顾了思维链的可审计和隐蔽性；adaptive jailbreak 成功率相比强基线降低 54% 以上，平均 ASR 约 9.4%，语义相似度约 0.96。

Pretending to Think: Unmasking and Eliminating Post-Hoc Rationalization in LLM Safety Chain-of-Thought

EMNLP 2026 Under Review, Meta 5, 独立一作

- 揭示安全 CoT 中的伪推理现象，发现模型拒答决策常在安全推理生成前已收敛，推理过程反受基于浅层特征的决策约束且难以对安全决策产生因果影响；提出 Safety-as-Reasoning，通过构建反事实数据集和时序/一致性训练约束与损失优化，增强安全推理因果性、降低过拒并提升越狱鲁棒性。

From Shallow Alignment to Source Correction: Robust Safety Alignment for LLMs

EMNLP 2026 Under Review, Meta 4, 独立一作

- 诊断 Depth-wise Alignment Discrepancy，发现有害向量主要在低层产生而常规安全对齐梯度集中在高层；提出 SAGA，通过建模数据集的熵值与训练梯度分布的关系，通过构建高熵数据集，将安全梯度引导到脆弱低层以消除这种分布差异，ASR 相比 SOTA 降低 21%-63%，额外开销小于 3%。

From Chain to Mesh: Evolving Robust Safety Alignment via Neuron-Circuit Topology

EMNLP 2026 Under Review, 0a3.5, 独立一作

- 从神经元回路拓扑解释安全对齐脆弱性以及局部失效和整体能力崩溃的关联；超越静态的神经元功能分析，建模神经元回路并发现安全回路的拓扑缺陷；提出 DSM 将安全神经元回路从脆弱单链结构转化为鲁棒网状结构；在多类越狱 / 微调 / 编辑扰动下具有更强的鲁棒性，并保持通用任务能力，动态 DSM 在迭代攻击中可将 ASR 维持在 3% 以下。

AgentVax: Turning Multi-Agent Communities from Safety Liabilities into Collective Defense

USENIX Security 预投稿, 独立一作

- 基于各类智能体在社交平台面对注入攻击时自发产生互相提醒的现象，提出 AgentVax 多智能体安全防御框架，将 Agent 安全从单模型拒答扩展到社群级风险协同治理，实现智能体社群免疫；构建 Input / RAG / Memory / Agent-Message / Tool-Chain Worm 评测，建模蠕虫传播与攻击抗体补丁传播的传播学对抗场景，并提出攻击免疫补丁 skill 的构建、优化、融合、传播与可信验证完整流程框架。

Think While You Learn: Deliberative Safety Training for Generalizable LLM Alignment

ICLR 2027 预投稿, 独立一作

- 提出模型自我能力认知不足源自于模型缺乏学习外界对自身输出结果的评价与反馈，构建自动化自我认知训练流程；构建训练阶段的模型自我能力认知与审慎式学习框架，利用模型自身推理能力边思考边学习，增强数据风险识别与过滤、规则抽象、行为泛化和自我反思，并扩展到安全、代码、语言、数学等能力的数据构建与模型训练。同时构建基于自我认知的自身评测数据集构建、训练时推理介入、训练数据优化和模型能力与认知同步训练全流程。

Safety Collapse: Revealing Representation Competition in LLM Safety Signals and Orthogonal Decomposition for Safer Generation

ICLR 2027 预投稿, 独立一作

- 揭示安全推理与非安全任务推理的在隐藏特征空间中的竞争与崩塌，在隐藏空间超越单一任务方向建模更精准的能力方向簇；提出 PRISM 正交表征干预方法，通过识别模型多任务竞争并拆分为并行推理实现多任务能力的保持；在 6 个主流 LLM 上同时降低攻击成功率和过拒绝率，ASR 平均下降约 28 个百分点、过拒绝率下降约 12 个百分点。同时在安全、数学、代码、语言、推理等多领域验证且适用。

竞赛荣誉与学术服务

- 2024 生成式人工智能安全大赛：越狱攻击赛道前三名、安全对齐赛道前三名。
- 本科及博士期间连续六年获得优秀学生/一等奖学金与三好学生。
- 大模型对齐训练专利 4 项，交易社群异常风险识别专利一项均处于公示阶段。
- 参与 ACL、AAAI 等 CCF A 类会议审稿。

个人评价

- **学习与迁移**：习惯通过论文精读、源码复现、实验 ablation 和失败案例复盘建立新方向认知，行动力强，能快速把模糊问题拆成可验证假设、最小实验和迭代计划。
- **工作方式**：对安全边界、证据链和结果可信度敏感，做事细致稳定、责任心强，适合长期攻关、高强度迭代和跨算法 / 工程 / 评测协作场景。